

# Detekcja uszkodzeń śmigieł w dronie przy użyciu metod uczenia maszynowego

Stanisław Kuczma, Artur Prentki, Michał Waszkowiak, Dawid Woźniak

**Abstract**—Praca skupia się na wykorzystaniu nowoczesnych metod uczenia maszynowego do identyfikacji uszkodzeń śmigieł w dronach podczas lotu. Dzięki zastosowaniu danych z czujników ruchu możliwe jest wczesne wykrywanie anomalii, które mogą wpływać na bezpieczeństwo i stabilność lotu. Badania wykazały, że różne techniki, takie jak autoenkodery czy algorytmy wykrywania anomalii, mogą skutecznie identyfikować uszkodzenia nawet w warunkach dużej zmienności danych. Proponowane rozwiązanie stanowi krok w kierunku autonomicznego monitorowania stanu technicznego UAV, zwiększając ich niezawodność i bezpieczeństwo operacyjne.

## I. WSTĘP

Celem projektu jest zastosowanie metod uczenia maszynowego do wykrywania uszkodzeń śmigieł w czterośmigłowym dronie. Eksperyment wykorzystuje zbiór danych przygotowany przez Laboratorium Robotów Latających na Politechnice Poznańskiej, obejmujący 20 przelotów, z których każdy trwa około 3 minuty. Rejestrowane są dane z IMU umieszczonych na pałkach drona, dzięki temu mamy dostęp do przyspieszeń oraz odchyień. W każdym locie mogły wystąpić dwa rodzaje uszkodzeń śmigieł: złamanie lub uszkodzenie bez złamania wynikające z uderzenia, które dla uproszczenia zakwalifikowano jako "śmigło uszkodzone". Dzięki temu zadanie sprowadzono do klasyfikacji binarnej: śmigło uszkodzone lub nieuszkodzone. Ze względu na specyfikę drona, dla każdego z czterech śmigieł trenowano oddzielny model, a dodatkowo analizowano wpływ uszkodzenia jednego śmigła na możliwość wykrycia uszkodzeń w pozostałych. Dataset jest opisany w sposób następujący, gdzie 4 ostatnie cyfry oznaczają kolejno uszkodzenia dla śmigieł A,B,C oraz D.

Rozwiązanie to pozwala na diagnozę uszkodzeń już w trakcie lotu, gdzie wizualna ocena jest nie-  
możliwa ze względu na prędkość obrotową.

W tym celu wyuczyliśmy i wyeksportowaliśmy 4 modele i przeprowadziliśmy badanie skuteczności detekcji uszkodzeń.

## II. RÓŻNE METODY

Ta sekcja zawiera opis różnych metod użytych do przeprowadzenia eksperymentu. Uczenie przeprowadzaliśmy niezależnie od każdego śmigła. Model był uczony na 2 przelotach. Jeden, gdzie wszystkie śmigła były sprawne, oznaczone numerem 0000, oraz jeden lot, gdzie wszystkie śmigła były uszkodzone, oprócz tego badanego. Czyli na przykład dla śmigła A było to 0122, a dla C 1102. Zbiór testowy składał się z dopełnienia zbioru uczącego.

### A. Autoenkoder- Stanisław Kuczma

1) *Opis metody:* Autoenkoder jest to sztuczna sieć neuronowa stosowana w uczeniu nienadzorowanym. Metoda polega na wyuczeniu wzorca, czyli kompresji danych wejściowych. Następnie sprawdza się dokładność na zbiorze uczącym, żeby określić próg błędu, który stanowi 95% uzyskanego wyniku.

2) *Trening:* Widać na grafice: 1, wraz z kolejnymi epokami maleje błąd treningowy. Jest to dobry znak dla poprawnego uczenia się modelu. Z racji na rozmiar danych, który nie był za duży, postanowiliśmy na sprawdzenie różnych kombinacji i rozmiarów batcha. Czas uczenia modelu nie przekraczał 2 minut.

### B. LSTM Autoencoder- Artur Prentki

LSTM autoenkoder to architektura sieci neuronowej składająca się z enkodera LSTM, który kompresuje sekwencje wejściowe do reprezentacji o mniejszym wymiarze, oraz dekodera LSTM, który rekonstruuje oryginalne dane z tej skompresowanej formy. Dzięki wykorzystaniu warstw




Fig. 1. Wykres traning loss dla batch= 2

LSTM (Long Short-Term Memory) model potrafi efektywnie przetwarzać dane sekwencyjne, zachowując informacje o zależnościach czasowych i wzorcach występujących w danych. Model ten jest szczególnie skuteczny w zadaniach takich jak wykrywanie anomalii w szeregach czasowych, ponieważ uczy się normalnych wzorców w danych i potrafi wykryć odstępstwa od nich. Dzięki tej zależności powinien mieć przewagę nad klasycznym autoenkoderem wnioskującą z danych sekwencyjnych.

### C. Isolation Forrest- Michał Waszkowiak

1) *Opis metody:* Isolation Forest to metoda uczenia nienadzorowanego stosowana do wykrywania anomalii, bazująca na iteracyjnym dzieleniu przestrzeni cech w sposób losowy. Dzięki tej technice punkty odstające, które wymagają większej liczby podziałów, są łatwiejsze do zidentyfikowania.

2) *Tworzenie lasu izolacji:* Model generuje wiele losowych drzew decyzyjnych, dzieląc przestrzeń cech na podzbiory. Punkty odstające są szybciej izolowane, co ułatwia ich detekcję.

Wyznaczanie progu anomalii Po przetrenowaniu modelu oblicza się wyniki anomalii dla każdego punktu. Próg wykrywania ustala się na poziomie 95% wartości wyników, analogicznie do metody autoenkodera. Punkty przekraczające ten próg uznawane są za anomalie.

### D. K-średnich- Dawid Woźniak

Metoda k-średnich (ang. k-means) to algorytm klasteryzacji stosowany w uczeniu nienadzorowanym, którego celem jest podział zbioru danych na  $k$  klastrów poprzez iteracyjne minimalizowanie sumy odległości punktów od ich centroidów. Algorytm rozpoczyna się od losowej inicjalizacji centroidów, a następnie w każdej iteracji przypisuje punkty danych do najbliższego centroidu oraz aktualizuje położenie centroidów jako średnią punktów w klastrze. Proces ten powtarza się do osiągnięcia zbieżności, gdy przypisanie punktów lub pozycje środków klastrów przestają się zmieniać. Metoda jest efektywna obliczeniowo, lecz wymaga wcześniejszego określenia liczby klastrów, gdzie w naszym przypadku nie stanowiło to problemu, ponieważ mieliśmy z góry określoną ilość klastrów.

## III. EWALUACJA

Aby ocenić skuteczność zastosowanej metody, postanowiliśmy przeanalizować wyniki na pozostałych 18 próbkach, korzystając z klasycznych metryk, takich jak precision, do oceny modelu. Spośród wszystkich próbek 9 reprezentuje przeloty bez uszkodzenia śmigła A, a pozostałe 9 zawiera przeloty z uszkodzonymi śmigłami A. Dla śmigieł A oraz B występują uszkodzenia tylko 1 typu z jednym wyjątkiem, analogicznie dla śmigieł C i D z jednym wyjątkiem występują tylko uszkodzenia 2 typu.

Dla każdej metody wykonaliśmy 4 modele, każdy dla jednego śmigła. Tabela I przedstawia wyniki zebrane dla poszczególnych metod oraz średnią wartość z każdej metody dla śmigła. Natomiast tabela II zawiera informację o średniej ze skutecznością danej metody bez względu na śmigło, oraz podział na średnią z śmigieł A i B oraz C i D.

	Autoenkoder	LSTM	I- Forrest	K-mean	Średnia
A	1	1	0,94	1	0,985
B	0,83	0,61	0,88	0,61	0,73
C	0,5	0,5	0,5	0,44	0,485
D	0,56	0,56	0,56	0,61	0,57

TABLE I

TABELA Z WYNIKAMI EKSPERYMENTU DLA KAŻDEGO Z ŚMIGIEŁ

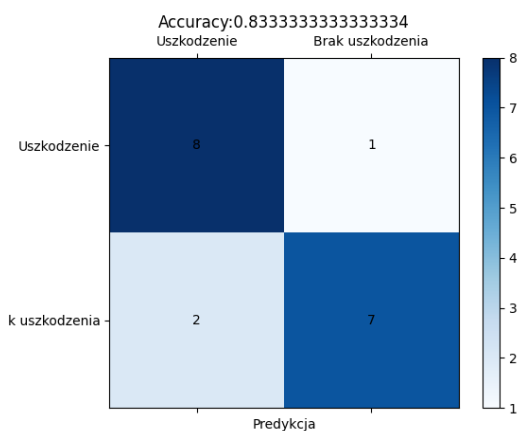


Fig. 2. Przykładowa macierz wyników dla metody Autoenkoder na śmigle B




Fig. 3. Przykładowa macierz wyników dla metody Isolation Forrest na śmigle B

#### IV. WNIOSKI

Po przeprowadzeniu eksperymentu można wyciągnąć kilka istotnych wniosków. Średnia skuteczność wykrywania anomalii przez modele wyniosła prawie 70%. Analiza danych ujawnia jednak pewien trend: wszystkie modele zdecydowanie lepiej radzą sobie z detekcją na śmigłach A i B niż na śmigłach C i D. Tendencję tę można zauważyć w tabeli I, w której ostatnia kolumna pokazuje, że średnia skuteczność dla grupy A/B wynosi ponad 85%.

Otrzymane wyniki pozwalają na bardziej szczegółową analizę rodzaju uszkodzeń. Początkowo założono, że uszkodzenia typu 1 i 2 będą klasyfikowane ogólnie jako "uszkodzenia". Jednak analiza histogramów danych z akcelerometru i żyroskopu

(rys. 4) wskazuje, że wartości dla uszkodzenia typu 2 oraz braku uszkodzeń są bardzo zbliżone. Natomiast uszkodzenie typu 1 (oznaczone kolorem niebieskim) cechuje się wyraźnie odmienną, dominującą wartością.

To zjawisko znajduje odzwierciedlenie w wynikach eksperymentu: na śmigłach A i B dominują uszkodzenia typu 1, natomiast na śmigłach C i D przeważają uszkodzenia typu 2. To wyjaśnia różnice w skuteczności detekcji między tymi grupami.




Fig. 4. Histogram dla danych pomiarowych z przelotu 1102

Skoro różnice występują między A/B i C/D to wartości w poszczególnych grupach powinny być podobne. Otóż nie do końca.




Fig. 5. Histogram dla danych pomiarowych z przelotu 1022

Analizując przelot 1022 przedstawiony na wykresach 5 i 6, zauważono, że histogramy dla śmigieł A i B są identyczne w obu grafikach. Z kolei dla śmigieł C i D widoczne są takie same




Fig. 6. Histogram dla danych pomiarowych z przelotu 1022

	Autoenkoder	LSTM	Isolation Forrest	K-mean
Średnia	0,72	0,67	0,72	0,66
A/B	0,915	0,805	0,9	0,8
C/D	0,53	0,53	0,53	0,53
A/D	0,78	0,78	0,75	0,805
B/C	0,665	0,555	0,69	0,525

TABLE II

TABELA Z WYNIKAMI EKSPERYMENTU BEZ WZGLĘDU NA ŚMIGŁO ORAZ PODZIAŁ NA ŚREDNIĄ ZE ŚMIGIEŁ A I B ORAZ C I D

uszkodzenia typu 2, obecne na obu wykresach. Jednocześnie śmigła te obracają się w przeciwnych kierunkach.

Średnia wartość histogramu dla śmigła C wynosi 0,6, podczas gdy dla śmigła D wynosi 0,3. Podobną zależność zaobserwowano również w innych próbkach. Sugeruje to, że skuteczność detekcji zależy nie tylko od rodzaju uszkodzenia, ale także od kierunku obrotu śmigła. W tabeli II widać potwierdzenie danych, że pary śmigieł kręcących się w jedną stronę w tym przypadku A/D są konsekwentnie lepsze dla czterech badanych metod.

## V. KOD ŹRÓDŁOWY

Kod, który powstał podczas pracy nad tym zadaniem, znajduje się pod tym linkiem. Tam również znajdują się wszystkie wyniki uzyskane w trakcie trwania eksperymentu.

## REFERENCES

- [1] Puchalski, R., Ha, Q., Giernacki, W. et al. PADRE – A Repository for Research on Fault Detection and Isolation of Unmanned Aerial Vehicle Propellers. *J Intell Robot Syst* 110, 74 (2024). <https://doi.org/10.1007/s10846-024-02101-7>

- [2] R. Puchalski, M. Kołodziejczak, A. Bondyra, J. Rao and W. Giernacki, "PADRE - Propeller Anomaly Data REpository for UAVs various rotor fault configurations," 2023 International Conference on Unmanned Aircraft Systems (ICUAS), Warsaw, Poland, 2023, pp. 982-989, doi: 10.1109/ICUAS57906.2023.10156238. keywords: Accelerometers;Vibrations;Propellers;Shape;Rotors;Autonomous aerial vehicles;Data models,
- [3] R. Puchalski, W. Giernacki and Q. Ha, "Real-Time UAV Fault Detection and Classification Using Measurement Data from the PADRE Database," 2024 IEEE/SICE International Symposium on System Integration (SII), Ha Long, Vietnam, 2024, pp. 663-668, doi: 10.1109/SII58957.2024.10417427. keywords: Propellers;Fault detection;Autonomous aerial vehicles;Robot sensing systems;Real-time systems;Safety;Drones,